


해외여행지 기반 국내여행지 추천 시스템



기저선대

AIR TICKET

1. 분석 배경
2. 데이터
3. 클러스터링
4. EDA

BOARDINGPASS

PASSENGER NAME:

FROM:

TO:

DATE TIME FLIGHT

SEAT GATE



1. 분석배경

- 주제 선정 배경
- 분석 배경
- 분석 흐름

정부의 국내 관광 활성화 정책

코로나19 이후 내수 진작을 위해
국내 관광 활성화 정책을 펼치고 있음




시는 정부의 '내수 활성화 대책'에 발맞춰 외래관광객 유치 및 소비촉진 대책 ' 을 가동한다고 4일 밝혔다.
이번 외국인 관광객 유치 정책을 통해 관광수지 적자를 완화한다는 방침이다.

해외 관광객을 위한 관광지 추천 가능

해외로 나가는 내국인 관광객은 늘고 있지만,
국내를 찾는 외국인 관광객 수요는 증가세가 더딤



[2022년 한국 출입국 관광객]



코로나19 이후 해외로 나가는 내국인 관광객은 늘고 있지만, 국내를 찾는 외국인 관광객 수요는 증가세가 더딘 상황이다. 지난 2월 기준 해외로 나간 내국인 관광객 수는 172만4880명에 달했지만, 국내를 찾은 외국인 관광객은 47만9248명으로 3분의 1 수준을 보였다.


출처- The JoongAng, [리모델링 급한 한국 관광] 진화 멈춘 한국 관광, 비용만 폭등 “차라리 외국으로”

해외 관광객을 위한 관광지 추천 가능

해외로 나가는 내국인 관광객은 늘고 있지만,
국내를 찾는 외국인 관광객 수요는 증가세가 더딤



[2022년 한국 출입국 관광객]



코로나19 이후 해외로 나가는 내국인 관광객은 늘고 있지만, 국내를

월 기준
안, 국내를
보였다.

등 "차라리 외국으로"

해외 여행을 가고자 하는 사람들에게
해외 여행지와 유사한 국내 여행지 추천



국내 여행 활성화에 초점을 둔 정부의 내수활성화 대책이 발표됨



해외로 나가는 내국인 관광객에 대해서,
해외로 나가는 대신 국내 여행을 할 유인의 필요성이 대두됨



해외 여행지 선택 이유를 분석해 **국내 여행지를 추천**해주자!

1

여행지 데이터 수집 및 EDA



2

국내 여행지 클러스터링을 통한 인사이트 도출



3

해외, 국내 여행지 유사도 계산을 위한 토픽 모델링 진행



4

컨텐츠 기반 국내 여행지 추천 시스템 구축



5

추천 정보를 활용한 관광 활성화 도모 목적의 관광지 정책 제언



2. 데이터

- 토픽 추출 데이터
- 크롤링 대상 선정
- 네이버 블로그 크롤링
- 크롤링 데이터 토큰화
- 변수 선정 기준
- 변수와 파생변수

해외 여행지와 유사도를 기반으로 국내 여행지를 추천하기 위해서는
여행지를 가는 이유가 비슷한 지역끼리 묶을 수 있어야 함

특정 여행지의 특징을 보여줄 수 있는 데이터를 고려



여행지 리뷰

여행지 요약문

네이버 블로그



트립어드바이저
여행자 리뷰



여행 및 호텔 예약 사이트의
여행지 요약문



네이버 블로그
여행 리뷰



트립어드바이저
여행자 리뷰

리뷰에는 그 여행지를 가는 이유와
여행지의 특징이 잘 드러나 있을 것이라고 예상

따라서 평점 4점 이상의 긍정 리뷰만을 활용하여
긍정 리뷰의 토픽을 뽑고자 함



트립어드바이저
여행자 리뷰



여행지에 대한 리뷰보다는
여행지의 각 명소별 리뷰만 존재함

이 경우 각 명소별 얼마나 리뷰를 모아야 하는지
기준을 설정하기 어려움



정보의 양은 많지만 질이 떨어지는 문제가 발생



여행 및 호텔 예약 사이트의
여행지 요약문

여행지 요약에는 여행지에 대한 자세한 설명과
가장 중요한 특징만 모아 놓기 때문에
토픽을 뽑기 용이하다고 예상

Tripadvisor

트립어드바이저
여행자 리뷰

blog

트립어드바이저 블로그
여행 리뷰



여행 및 호텔 예약 사이트의
여행지 요약문



충분한 데이터 수집을 위해서는
각 여행지마다 충분한 양의 요약문이 있어야 하지만
많은 양의 요약문을 찾을 수 없었음



정보의 질은 굉장히 높지만 양이 부족한 문제가 발생

네이버 블로그 글은 직접 여행 다녀온 것을
자세히 작성해 놓은 정보라고 볼 수 있음

각 여행지 별 수백 건의 글이 존재하기에
정보의 양은 충분함



네이버 블로그
여행 리뷰

[2022. 매경헬스. 고(高)물가 시대, 나만의 가성비 여행 방법은?]

◆ 숙박지·맛집 정보 찾을 때는 '이 사이트 검색'

응답자의 과반수 이상이 숙박지 선택을 네이버(52.8%)를 이용했다. 이어 여기어때, 인터파크 등 여행 사이트(21.4%) > 구글 검색(9.9%) > 한국관광공사(8.9%) > 지인 추천(6.8%) 순으로 나타났다.

맛집 정보는 응답자 70% 이상이 네이버를 이용하는 것으로 파악됐다. 2위는 구글 검색(13.3%)이었으며, 식신(2.9%) > 다이닝코드(2%) > 티맵(1.4%) 순을 보였다. SNS 검색 등 기타 의견도 있었다.

요약문



네이버 블로그
여행 리뷰

많은 사람들이 여행 정보를 네이버 블로그를 통해 수집함을 알 수 있음

[2022. 매경헬스. 고(高)물가 시대, 나만의 가성비 여행 방법은?]

◆ 숙박지·맛집 정보 찾을 때는 '이 사이트 검색'

응답자의 과반수 이상이 숙박지 선택을 네이버(52.8%)를 이용했다. 이어 여기어때, 인터파크 등 여행 사이트(21.4%) > 구글 검색(9.9%) > 한국관광공사(8.9%) > 지인 추천(6.8%) 순으로 나타났다.

맛집 정보는 응답자 70% 이상이 네이버를 이용하는 것으로 파악됐다. 2위는 구글 검색(13.3%)이었으며, 식신(2.9%) > 다이닝코드(2%) > 티맵(1.4%) 순을 보였다. SNS 검색 등 기타 의견도 있었다.

요약문



네이버 블로그
여행 리뷰

여행지 선택에 있어서 자세한 정보를 담고 있기 때문에 정보의 질도 높고 양도 충분함

[2022. 매경헬스. 고(高)물가 시대, 나만의 여행지 선정 기준은?]

◆ 숙박지·맛집 정보 찾을 때는 '이 사이트 검색'

응답자의 과반수 이상이 숙박지 선택을 네이버(52.8%)를 이용했으며, 여행 사이트(21.4%) > 구글 검색(9.9%) > 한국관광공사(8.9%) > 지

맛집 정보는 응답자 70% 이상이 네이버를 이용하는 것으로 파악됐다. 2위는 구글 검색(13.3%)이었으며, 식신(2.9%) > 다이닝코드(2%) > 티맵(1.4%) 순을 보였다. SNS 검색 등 기타 의견도 있었다.



네이버 블로그

여행 리뷰

정보의 양과 질의 Trade-Off를 고려하여

여행지에 대한 자세한 정보가 서술되어 있는 **네이버 블로그** 선택

여행지 선택에 있어서 정보의 질도 높고 양도 충분함



셀레니움(Selenium)

사이트의 다양한 HTML 요소에 클릭,
키보드 입력 등 이벤트를 주고
파이썬에서 인터넷 브라우저를
제어할 수 있게 하는 모듈

크롤링 대상 여행지

국내

: 세종시를 제외한 228개 시군구

해외

↙ : 136개의 도시

*국민 해외관광 주요 목적지 통계를 참고하여
상위 국가의 도시 선정

검색어

국내

: 여행지 이름 +
여행 / 여행 이유 / 가볼만 / 여행 추천

해외

: 여행지 이름 +
여행 / 여행 이유 / 자유여행 /
가볼만 / 여행 추천

크롤링 대상 여행지

국내

: 세종시를 제외한 228개 시군구

해외

: 136개의 도시

*국민 해외관광 주요 목적지 통계를 참고하여
상위 국가의 도시 선정

검색어

국내


: 여행지 이름 +

여행 / 여행 이유 / 가볼만 / 여행 추천

해외

: 여행지 이름 +

여행 / 여행 이유 / 자유여행 /
가볼만 / 여행 추천



가볼만 한 곳이 아닌 가볼만으로 검색어를 설정한 이유는?

국내 : 검색 결과에 엉뚱한 장소가 나오는 문제가 있어서
 : 세종시를 제외한 228개 시군구
 : 여행지 이름 +
 가볼만으로 검색어 변경
 여행 / 여행 이유 / 가볼만 / 여행 추천

국내 검색어에는 자유여행이 없는 이유는?

해외 : 136개의 국가
 : 여행지 이름 +
 *국민 해외관광 주요 목적지 통계를 참고하여
 : 국내 지역 검색에 자유여행을 추가하면
 상위 국가의 도시 선정
 여행 / 여행 이유 / 자유여행 /
 가볼만 / 여행 추천
 여행 관련 블로그만을 검색하지 않기 때문에 제거

크롤링 과정에서 잘못된 도시나 아예 무관한 블로그 글이 크롤링 된 경우가 있었음

① 잘못된 도시의 경우

Ex) 경상북도 경산시의 경우 중국의 경산이 크롤링 된 경우가 50% 이상



```
country = {  
    '경북' : ['경북 경산']  
}
```

'경산'으로 검색하지 않고
'경북 경산'으로 검색

크롤링 과정에서 **잘못된 도시나 아예 무관한 블로그 글이 크롤링** 된 경우가 있었음

② 무관한 블로그의 경우

Ex) 서울시 금천구의 경우 강원도 강릉의 금천칼국수를 크롤링 한 경우가 있음



DAY1
강릉 ktx역 도착 - 금천칼국수 - 중앙시장 - 만동제과 - 강문해변 (숙소)
청량리역에서 여덟시 사십오분에 출발해서
강릉에 열시반에 도착했다
이 기차 타려고 꼭두새벽에 일어남 😓
이른 아침이라 나름 한산한 청량리역
신기해서 찍어본 자리마다 있는 무선충전기!
핸드폰 넣어놓기만 하면 (유에스비 선 필요없이)
자동으로 충전된다 세상 참 좋아졌어
강릉역 도착하자마자 택시 잡고 금천칼국수로 이동했다
역에서 택시로 십분거리

직접 제거해주는 방식 선택

필터링을 통해 완성시킨 블로그 크롤링 데이터

	제목	링크	내용	country	city
0	친구가족들과 1박2일 가평여행:D (프롬밀크 카페...	https://blog.naver.com/emily_0217/223020320907	2월 초에 다녀온 세가족 가평 1박2일 기록해보려 한다.\n남편 친구네 가족이지만 나...	경기	가평
1	경기도 가볼만한곳 가평 여행 관광지 동물체험 지 동물체험 가평 양떼목장...	https://blog.naver.com/tcacyc/222979562087	경기도 가볼만한곳 가평 여행 관광지 동물체험 가평 양떼목장 동물원\n서울 근교에 있...	경기	가평
2	청량리역 ktx, itx 카페, 김밥 등 feat. 가평여행	https://blog.naver.com/pinkplum80/222975800122	가벼운 남이섬-가평 여행을\n시작하는 날,\n일찌 감치 청량리역 ktx, itx 에 ...	경기	가평
3	가평여행 설악막국수 추천닭갈비 먹고왔어요	https://blog.naver.com/coom91/223039250726	50m\n© NAVER Corp.\n설악막국수추천닭갈비 서관\n경기도 가평군 설악면...	경기	가평
4	[가평여행 장보기] 마트 물가비교1. 조은마트(픽업) vs 와캠핑...	https://blog.naver.com/gud_log/223051140444	오늘은 요새 제가 가평여행을\n한달에 2~3번 가 면서 잇님들께 도움될만한 정보가\n...	경기	가평
...	...	...	...	...	...
82502	횡성 여행 리포터 추천 맛집! 횡성더덕 ...	https://blog.naver.com/himawari_tw/222044996596	강\n원도 횡성에서 유명한 것이 바로 '더덕'이죠. 횡성더덕으로 코스요리를 전문으로...	강원	횡성



국내 : 82,507건, 해외 : 82,507건
총 142,856건

주어진 코퍼스(corpus)에서 토큰(token)이라 불리는 단위로 나누는 작업을
토큰화(tokenization)라고 함

Okt
(Open Korea Text)

메캅
(Mecab)

한나눔
(Hannanum)

꼬꼬마
(Kkma)

네이버 블로그 원문 예시

안녕하세요 바리콩입니다 😊 코로나가 전세계를 잠식하기 전 19년 12월 마지막 여행 한곳이 바로
방콕 이었는데요 천사의 도시이자 자유여행자들의 천국인 방콕 자유여행을 다시 준비하고있답니다
🏰 그래서 오늘은 ! 저처럼 방콕 자유여행을 준비하시는 분들을 위해 도움이 될 수 있도록 방콕
항공권 그리고 자유여행 코스 기록해볼까해요 😊 ...

Okt

토큰화 속도

데이터 10,000 건당
약 30분의 시간 소요

토큰화 성능

명사 만을 추출했을 때
부사 등도 종종 나오는
것을 볼 수 있지만
대체적으로 고유 명사를
잘 추출함

토큰화 예시

밤 일정 문화유산 접속 잠식
생각 더위 모든 예전 가격 예산
기록 확인 더 거리 기운 좀 점심
이해 경우 대형 음식 신청
항공사 투어 쫓 환율 변동

Okt

토큰화 속도

토큰화 성능

토큰화 예시

'좀', '쫘' 같은 단어도 토큰화 된 것을 볼 수 있지만
전체적으로는 토큰화 성능이 우수함

밤 일정 문화유산 접속 잠식
생각 더위 모든 예전 가격 예산
기록 확인 더 거리 기운 좀 점심
이해 경우 대형 음식 신청
항공사 투어 쫘 환율 변동

Mecab

토큰화 속도

데이터 10,000 건당
약 1분의 시간 소요

토큰화 성능

Mecab은 명사를
더 잘게 나누기 때문에 Okt보다
조금 더 세분화된 명사도
확인 가능

토큰화 예시

밤 원 일정 문화유산 접속 잠식
생각 로드 더위 예전 가격 예산
기록 확인 거리 기운 점심 이해
경우 대형 음식 신청 항공사
투어 썸 환율 변동 방콕 마무리
령 예약 기차길 상품 온라인 만
하나 식당 바리

Mecab

토큰화 속도

Okt와 비슷한 결과 확인

명사를 잘게 나누기 때문에 '렁' 같은 알 수 없는

명사도 추출

'왓아룬' 같은 고유명사는 추출하는 경우도 있고

못하는 경우도 있음

토큰화 성능

토큰화 예시

밤 원 일정 문화유산 접속 잠식
생각 로드 더위 예전 가격 예산
기록 확인 거리 기운 점심 이해
경우 대형 음식 신청 항공사
투어 썸 환율 변동 방콕 마무리
렁 예약 기차길 상품 온라인 만
하나 식당 바리

Hannanum

토큰화 속도

데이터 10,000 건당
약 40-50분의
시간 소요

토큰화 성능

특수문자, 숫자, 이모티콘
등도 명사와 함께 추출됨

토큰화 예시

70130 ☺ 다양한 10200 밤
굿초이스 일정 접속 잠식 생각
더위 간단 예전 가격 예산 기록
확인 거리 ♡ 기운 점심 이해
경우 대형 신청 항공사 들 투어
썸 환율 변동 19년

Hannanum

토큰화 속도

연결된 숫자는 같이 출력됨을 볼 수 있음
'기록해볼까해요', '시간이었답니당', '있답니당' 같이
명사 토큰화가 완벽하지 않은 경우가 있음

토큰화 성능

토큰화 예시

70130 ☺ 다양한 10200 밤
굿초이스 일정 접속 잠식 생각
더위 간단 예전 가격 예산 기록
확인 거리 ♡ 기운 점심 이해
경우 대형 신청 항공사 들 투어
썸 환율 변동 19년

Kkma

토큰화 속도

4가지 토큰화 방식
중에서 가장 오래 걸림

토큰화 성능

숫자와 한 단어로 된 명사도
추출되지만 전반적으로
명사 추출은 잘 됨

토큰화 예시

70130 10200 밤 네스
굿초이스 일정 접속 잠식 생각
로드 더위 안녕하세 모든 가격
예전 기록 확인 거리 예산 기운
점심 이해 경우 오산 음식 대형
신청 산 항공사 투어 썸 환율

Kkma

토큰화 속도

연결된 숫자는 같이 출력됨을 볼 수 있음
'안녕하세', '여행하세' 처럼 '요'만 제거한 단어가 많음

토큰화 성능

명사 추출은 잘 됨

토큰화 예시

70130 10200 밤 네스
굿초이스 일정 접속 잠식 생각
로드 더위 안녕하세 모든 가격
예전 기록 확인 거리 예산 기운
점심 이해 경우 오산 음식 대형
신청 산 항공사 투어 썸 환율



토큰화 결과 비교

속도 성능 : mecab >>> okt > hannanum > Kkma

토큰화 성능 : okt > mecab > Kkma > hannanum

토큰 개수(블로그 100개 기준) : Kkma > hannanum > okt > mecab



토큰화 결과 비교

우리 데이터에 맞는 토큰화 방법인

okt와 mecab을 이용해서 토큰화 진행

속도 성능 : mecab >>> okt > hannanum > Kkma

토큰화 성능 : okt > mecab > Kkma > hannanum

토큰 개수(블로그 100개 기준) : Kkma > hannanum > okt > mecab

여행지 유사도와 더불어 사용자에게 맞는
국내 관광지 추천을 위한 **국내 여행지의 특성을 나타낼 수 있는 변수** 선정

변수	파생변수
거리	-
여행 동반자 유형	-
2022, 2023년 방문자수	방문자 증가율
22년 3월 & 23년 3월 SNS 언급량	계절별 트렌드, SNS 언급량 변화율, 최신타렌드
카테고리	-
축제	-

한국관광 데이터랩



지역별 동반 유형, 지역별 방문자수,
지역별 SNS언급량, 유형별 검색건수 등

카카오 API



각 지역의 X, Y좌표

- 변수(거리)

Visa '로드 투 트래블 리커버리' 보고서

현지 정부의 규제 및 안전 수준 우수하며 이동거리 짧은 여행지 선호

아시아 태평양 지역 소비자들은 현지 정부의 규제 및 안전관리 수준이 우수하며 이동거리가 짧은 여행지를 선호하는 경향이 뚜렷했다. 또한 외진 곳 (remoteness)에 대한 선호도 높아졌다.

온라인 검색량을 분석한 결과, 한국 소비자들의 경우 하와이, 호주, 독일, 러시아, 미국, 필리핀, 인도네시아 순으로 여행지에 대한 관심이 높았으며, 이 중 필리핀을 제외한 모든 여행지는 팬데믹 이전 대비 관심이 증가했다.



많은 사람들이 이동거리가 짧은 여행지를 선호함

따라서 **거리가 여행 목적지 선정에 큰 영향을 준다는 것을 알 수 있음**

2) 성균관대학교부터 각 여행지까지 하버사인 거리를 구함

1) 카카오 API를 통해 각 지역의 X, Y 좌표를 구함

```
for val in country.values():
    for j in val:
        new = api.search_address(j, dataframe=True)
        df = df.append(new, ignore_index=True)
```

출발지(학교)로부터의 거리

각 여행지끼리의 거리

Distance Matrix -> 나중에 유사도 점수 계산할 때 neighbor의 경우 가중치를 주어 점수에 같이 계산하기 위해 weighted matrix 형성을 위한 distance matrix

```
n = len(df)
distance_matrix = pd.DataFrame(index=df['address_name'], columns=df['address_name'])

for i in range(n):
    for j in range(n):
        a = (float(df.loc[i, 'y']), float(df.loc[i, 'x']))
        b = (float(df.loc[j, 'y']), float(df.loc[j, 'x']))
        distance_matrix.at[df.loc[i, 'address_name'], df.loc[j, 'address_name']] = haversine(a, b, unit="km")
```

- 변수(동반자 유형)

한국문화관광연구원 '국민 여행 조사'

(서울=연합뉴스) 이태수 기자 = 지난해 우리 국민은 여러 가지 여행 형태 가운데 '가족 여행'을 가장 선호한 것으로 나타났다.

4일 한국문화관광연구원의 '국민 여행 조사' 기반 인포그래픽스에 따르면 지난해 국내 관광여행 동반자 유형으로는 가족이 55.1%로 가장 큰 비중을 차지했다.

친구·연인(38.1%)이 2위에 올랐고 친목단체·모임(5.2%), 친척(3.1%), 직장 동료(2.2%) 등이 뒤를 이었다.



지난해 우리 국민은 여러 가지 여행 형태 가운데 '가족 여행'을 가장 선호함
동반자 유형은 가족, 연인, 싱글(혼자 여행), 친구, 회사동료 등으로 다양하게 나뉨

동반자 유형에 따라 여행 행태가 달라짐

- 변수(동반자 유형)

동반유형 키워드 ⓘ ...

11	배우자	남편	390
12	친구	지인	282
13	연인	남자친구	280
14	연인	여자친구	212
15	자녀	아들	202

- 변수(동반자 유형)

동반유형 키워드 ⓘ

...

11	배우자	남편	390
12	친구	지인	282
13	연인	남자친구	280
14	연인	여자친구	212
15	자녀	아들	202

분류가 너무 다양하다는 문제 발생



배우자 → 연인으로 분류

자녀, 부모님 등 → 가족으로 분류

- 변수(동반자 유형)

동반유형 키워드 ⓘ

11	배우자	남편	390
12	친구	지인	282
13	연인	남자친구	280
14	연인	여자친구	212
15	자녀	아들	202

분류가 너무 다양하다는 문제 발생



배우자 → 연인으로 분류

자녀, 부모님 등 → 가족으로 분류

- 변수(동반자 유형)

동반자 유형			
가족, 연인, 싱글, 친구, 회사동료			

12	친구	지인	282
13	연인	남자친구	280
14	연인	여자친구	212
15	자녀	아들	



배우자 → 연인으로 분류
자녀, 부모님 등 → 가족으로 분류


최종적으로 5개의 카테고리를 생성

- 변수(동반자 유형)

동반자 유형 최종 데이터

광역시자체명	기초지자체명	가족_동반	연인_동반	싱글_동반	친구_동반	회사동료_동반
강원	강릉시	0.580907	0.061847	0.00656	0.341335	0.009351
강원	고성군	0.357731	0.278914	0.003219	0.34742	0.012715
강원	동해시	0.569502	0.11216	0.010724	0.257368	0.050246
강원	삼척시	0.577176	0.126847	0.018435	0.226189	0.051353
⋮	⋮	⋮	⋮	⋮	⋮	⋮

- 변수(동반자 유형)



동반 유형별 방문자 수 확인



가족 > 연인 > 친구 > 회사동료 > 싱글
순으로 방문자수가 많음

- 변수(동반자 유형)

동반자 유형 최종 데이터

광역지자체명	기초지자체명	가족_동반	한인_동반	싱글_동반	친구_동반	회사동료_동반
강원	강릉시	0.580907	0.061847	0.00036	0.341335	0.00351
강원	고성군	0.357731	0.278914	0.003219	0.34742	0.012715
강원	동해시	0.569502	0.11216	0.010724	0.257368	0.050246
강원	삼척시	0.577176	0.126847	0.018435	0.226189	0.051353
⋮	⋮	⋮	⋮	⋮	⋮	⋮



대부분의 지역에서 가족 동반이 가장 많은 유형

다른 지역에 비해 특정 유형이 높은 지역을 찾고자
각 비율을 비율의 평균으로 나눠 줌

- 변수(방문자 수)

일상생활권(거주, 통근, 통학 등)을 벗어나 관광 등의 목적으로
한 장소(분석 대상 공간)에 일정시간이상 체류한 사람의 수

광역시자치명	기초지자치명	1월 기초지자체 방문자 수	2월 기초지자체 방문자 수	...	23-2월 기초지자체 방문자 수	23-3월 기초지자체 방문자 수
강원	강릉시	2976083	2453981	...	2718362	2999758
강원	고성군	943992	803169	...	880512	848900
강원	동해시	925393	767711	...	848962	924943
강원	삼척시	863188	715674	...	754208	975015
⋮	⋮	⋮	⋮	...	⋮	⋮

- 파생변수(방문자 수 증가율)

광역시자치체명	기초자치체명	...	23년 방문자 증가율
강원	강릉시	...	1.30492
강원	고성군	...	1.29986
강원	동해시	...	1.10084
⋮	⋮	⋮	⋮

2022년과 2023년의 방문자 수를
토대로 2023년 방문자 증가율이라는
파생 변수를 생성함

*이때 가장 최근인 3월만 고려함



22년 대비 23년 증가율을 통해 어떤 지역이 눈에 띄게 방문자가 증가했는지 확인할 수 있음

- 파생변수(계절별 트렌드)

<지역별 방문자수 추이>

광역시자체명	기초지자체명	1월 기초지자체 방문자 수	2월 기초지자체 방문자 수	...	23-2월 기초지자체 방문자 수	23-3월 기초지자체 방문자 수
강원	강릉시	2976083	2453981	...	2718362	2999758
강원	고성군	943992	803169	...	880512	848900
⋮	⋮	⋮	⋮	...	⋮	⋮



시계열 분석을 통해 계절 트렌드 파악

- 파생변수(계절별 트렌드)

시계열 데이터 분해 방법

덧셈 분해

데이터

$$y_t = S_t + T_t + R_t$$

계절성분 추세 불규칙요소

데이터를 계절성분, 추세,
불규칙요소의 **합**으로 나타냄

곱셈 분해

$$y_t = S_t * T_t * R_t$$

데이터를 계절성분, 추세,
불규칙요소의 **곱**으로 나타냄


- 파생변수(계절별 트렌드)

시계열 데이터 분해 방법

덧셈 분해

$$y_t = S_t + T_t + R_t$$


데이터를 계절성분, 추세,
불규칙요소의 **합**으로 나타냄



트렌드와 무관하게 **변동폭이 일정할 때** 덧셈분해 사용

- 파생변수(계절별 트렌드)

시계열 데이터 분해 방법



트렌드에 따라 변동폭이 변할 때 곱셈분해 사용


곱셈 분해

$$y_t = S_t * T_t * R_t$$

데이터를 계절성분, 추세,
불규칙요소의 곱으로 나타냄

- 파생변수(계절별 트렌드)

강원도 홍천군의 시계열 분해




추세와 상관없이 변동폭이 일정하다고 판단
→ 덧셈 분해 사용

코로나 lockdown 해제로 인해
방문자 추세가 상승한 모습!

우리가 확인하고자 하는 계절성 :
해마다 어떤 특정한 계절 혹은 달마다
나타나며 데이터에 영향을 주는 패턴

- 파생변수(계절별 트렌드)

강원도 홍천군의 시계열 분해



추세와 상관없이 변동폭이 일정하다고 판단

→ 덧셈 분해 사용

코로나 lockdown 해제로 인해

방문자 추세가 상승


우리가 확인하고자 하는 계절성 :

해마다 어떤 특정한 계절 혹은 달마다

나타나며 데이터에 영향을 주는 패턴

- 파생변수(계절별 트렌드)

강원도 홍천군의 시계열 분해



추세와 상관없이 변동폭이 일정하다고 판단


→ 덧셈 분해 사용

우리가 확인하고자 하는 계절성 :

해마다 특정한 계절 혹은 달마다 나타나며

데이터에 영향을 주는 패턴

- 파생변수(계절별 트렌드)




분해 결과, 대부분의 지역에서
휴가철인 **7,8월**의 계절성이 높게 나타남



min-max 스케일링 진행 후
클러스터링

- 파생변수(계절별 트렌드)




분해 결과, 대부분의 지역에서
휴가철인 **7,8월**의 계절성이 높게 나타남



min-max 스케일링 진행 후
클러스터링

- 파생변수(계절별 트렌드)


Cluster 0



1. 강원도 고성군
2. 강원도 태백시
3. 경상남도 통영시

⋮

Cluster 1




1. 부산 해운대구
2. 강원도 강릉시
3. 제주도 제주시

⋮


- 파생변수(계절별 트렌드)

Cluster 0



1. 강원도 고성군
 2. 강원도 태백시
 3. 경상남도 통영시
- ⋮

Cluster 1



1. 부산 해운대구
 2. 강원도 강릉시
 3. 제주도 제주시
- ⋮



관광객 수가 여름에 특히 두드러지는 지역, 겨울이 두드러지는 구역으로 클러스터링 됨

→ 계절별 트렌드를 변수로 사용하는 것이 의미 있음

- 변수(SNS 언급량)

소셜미디어에서 관광 관련으로 해당 지역을 언급한 언급량 추이

광역시자체명	기초지자체명	23년 1월 언급량	23년 1월 언급량 비율	23년 3월 언급량	23년 3월 언급량 비율
강원	강릉시	26624	0.03819	24179	0.02698
강원	고성군	12522	0.017962	3969	0.00443
강원	동해시	8051	0.011549	7798	0.0087
강원	삼척시	1789	0.002566	2031	0.00227
⋮	⋮	⋮	⋮	⋮	⋮

- 변수(SNS 언급량)

각 지역이 얼마나 SNS에 언급되는지 파악하는 것은 **여행 트렌드 파악**에 아주 중요함

광역시자체명	기초지자체명	23년 1월 언급량	23년 1월 언급량 비율	23년 3월 언급량	23년 3월 언급량 비율
강원	강릉시	26624	0.03819	24179	0.02698
강원	고성군	12522	0.017962	3969	0.00443
강원	동해시	8051	0.011549	7798	0.0087
강원	삼척시	1789	0.002566	2031	0.00227
⋮	⋮	⋮	⋮	⋮	⋮

- 파생변수(SNS 언급량 변화율)

광역시자치체명	기초자치체명	1월 언급량 변화율	3월 언급량 변화율
강원	강릉시	0.908166	0.882413
강원	고성군	0.316962	0.715135
강원	동해시	0.968575	0.899631
⋮	⋮	⋮	⋮

1월 언급량 변화율 =
23년 1월 언급량 / 22년 1월 언급량

3월 언급량 변화율 =
23년 3월 언급량 / 22년 3월 언급량



SNS 언급량 변수를 바탕으로 SNS 언급량의 변화율이라는 파생 변수를 생성

- 파생변수(트렌드)

해당 지역이 얼마나 트렌디한지를 확인할 수 있도록 트렌드 파생변수 생성


- 1월 트렌드 = 1월 언급량 * 작년 대비 언급량 변화율
- 3월 트렌드 = 3월 언급량 * 작년 대비 언급량 변화율

광역시자체명	기초지자체명	1월 트렌드	3월 트렌드	광역시자체명	기초지자체명	1월 트렌드	3월 트렌드
경북	경주시	102668.0249	56568.91162	충남	예산군	272078.1512	213.4438481
충북	청주시	166382.9839	54187.04014	경기	수원시	254719.1332	21566.98868
충남	공주시	97083.73	45222.10507	충북	청주시	166382.9839	54187.04014
서울	종로구	158005.1472	41479.84028	서울	종로구	158005.1472	41479.84028
서울	마포구	128166.0552	26845.00183	서울	마포구	128166.0552	26845.00183
전북	전주시	116663.7669	21628.35567	전북	전주시	116663.7669	21628.35567
경기	수원시	254719.1332	21566.98868	경북	경주시	102668.0249	56568.91162
강원	강릉시	100339.6408	21335.86515	강원	강릉시	100339.6408	21335.86515
서울	강남구	88718.09146	21009.11096	충남	공주시	97083.73	45222.10507
서울	성동구	75163.67813	20174.77289	서울	강남구	88718.09146	21009.11096

23년 1월 트렌드 1위
: 예산군

- 파생변수(트렌드)

광역지자체명	기초지자체명	1월 트렌드	3월 트렌드
충남	예산군	272078.1512	213.4438481
경기	수원시	254719.1332	21566.98868
충북	청주시	166382.9839	54187.04014
서울	종로구	158005.1472	41479.84028
서울	마포구	128166.0552	26845.00183
전북	전주시	116663.7669	21628.35567
경북	경주시	102668.0249	56568.91162
강원	강릉시	100339.6408	21335.86515
충남	공주시	97083.73	45222.10507
서울	강남구	88718.09146	21009.11096



예산시장 백종원거리

트렌드 파생변수 생성

1월 언급량 * 작년 대비 언급량 변화율

3월 언급량 * 작년 대비 언급량 변화율

1월은

백종원 예산시장 프로젝트가
인기를 끌기 시작한 시점

23년 1월 트렌드 1위

: 예산군

- 파생변수(트렌드)

광역시자체명	기초지자체명	1월 트렌드	3월 트렌드
충남	예산군	272078.1512	213.4438481
경기	수원시	254719.1332	21566.98868
충북	청주시	166382.9839	54187.04014
서울	종로구	158005.1472	41479.84028
전북	전주시	116663.7669	21628.35567
경북	경주시	102668.0249	56568.91162
강원	강릉시	100339.6408	21335.86515
충남	공주시	97083.73	45222.10507
서울	강남구	86718.09146	21039.11096




이처럼 트렌드 변수를 통해 해당 지역이

실제로 얼마나 인기를 끌고 있는지 확인할 수 있음




사진 보기



예산시장 백종원거리

- 변수(대규모 축제)



대규모 축제는 방문자 유입을
증가시킴



***대규모 축제: 20만명 이상 방문 축제**
상위 80% 값이 197778.2이기 때문에,
20만명 이상을 대규모 축제로 봄

- 변수(대규모 축제)

<축제 최종 데이터>

광역시자체명	기초지자체명	축제명	축제유형	개최기간	방문객수
서울	영등포구	17회 영등포 여의도 봄꽃축제	문화예술	4.4~1.9	5,230,000
부산	해운대구	해운대 빛축제	문화예술	12월중	3,787,000
전남	영양군	영암왕인문화축제	문화예술	4.6~4.9	3,570,000
⋮	⋮	⋮	⋮	⋮	⋮

- 변수(카테고리)

티맵 네비게이션 사용자가 목적지를 조회하고 100m & 1분 이상 이동한 행위에 대한 건수

광역지자체명	기초지자체명	티맵카테고리 중분류명	티맵카테고리 중분류명	유형별 검색건수	유형별 검색건수비율
제주	서귀포시	자연관광	자연생태	3997	0
제주	서귀포시	자연관광	자연생태(산)	34212	0.4
제주	서귀포시	자연관광	자연공원	394165	1
제주	서귀포시	역사관광	역사유적지	54653	0.6
⋮	⋮	⋮	⋮	⋮	⋮

- 변수(카테고리)

유형	세부유형
자연관광	산, 하천/해양, 공원, 생태
역사관광	종교성지, 역사유적지, 역사유물
체험관광	공예, 농/산/어촌체험, 웰니스관광
문화관광	공연, 테마공원, 전시, 복합관광, 랜드마크, 기타문화, 도시공원, 도시/지역문화
레저스포츠	항공레저, 기타레저, 수상레저, 육상레저
쇼핑	대형마트, 면세점, 쇼핑몰, 백화점, 전문매장/상가, 시장
음식	한식, 외국식, 전문음식, 음식점기타, 카페/찻집, 간식음식
숙박	호스텔, 모텔, 펜션/민박, 콘도미니엄, 캠핑, 호텔, 기타숙박
기타관광	교통시설, 기타관광, 데이트코스

- 변수(카테고리)

유형	세부유형
자연관광	산, 하천/해양, 공원, 생태
역사관광	종교성지, 역사유적지, 역사유물
체험관광	공예, 농/산/어촌체험, 웰니스관광
문화관광	공연, 테마공원, 전시, 복합관광, 랜드마크, 기타문화, 도시공원, 도시/지역문화
레저스포츠	산과 바다는 여행지를 선택할 때 나눠서 생각하기에 하나의 군집으로 묶이면 안됨
쇼핑	따라서 바다를 따로 대분류로 만들었음 대형마트, 편의점, 백화점/대형점, 전문매장/상가, 시장
음식	한식, 외국식, 전문음식, 음식점기타, 카페/찻집, 간이음식
숙박	호스텔, 모텔, 펜션/민박, 콘도미니엄, 캠핑, 호텔, 기타숙박
기타관광	교통시설, 기타관광, 데이트코스

- 변수(카테고리)

유형	세부유형
자연관광	대형마트와 시장이 해당 분류에 잘 맞지 않다고 생각 → 대형마트를 가려고 여행지를 고려하지는 않음
역사관광	시장은 단순한 쇼핑 목적이 아니라고 생각 → 음식 또는 체험 카테고리 고려
체험관광	↓
문화관광	대형마트는 기타로 분류
레저스포츠	시장은 다른 카테고리의 세부유형을 고려해 유지
쇼핑	대형마트, 면세점, 쇼핑몰, 백화점, 전문매장/상가, 시장
음식	한식, 외국식, 전문음식, 음식점기타, 카페/찻집, 간식음식
숙박	호스텔, 모텔, 펜션/민박, 콘도미니엄, 캠핑, 호텔, 기타숙박
기타관광	교통시설, 기타관광, 데이트코스

- 변수(카테고리)

	콘도미니엄이 높게 나온 지역은 대부분 스키장이 많은 강원도 지역 → 레저 카테고리 고려
자연관광	캠핑은 숙박보다는 여행 그 자체가 될 수도 있다고 생각
역사관광	종교성지, 역사유적지, 역사유물
체험관광	콘도미니엄을 레저 카테고리에 넣으면 스키 이외의 요인이 고려되지 않음
문화관광	캠핑 또한 다른 카테고리의 세부유형을 고려했을 때 옮기기 애매한 문제가 발생
레저스포츠	항공레저, 기타레저, 수상레저, 육상레저
쇼핑	대형마트, 면세점, 쇼핑몰, 백화점, 전문매장/상가, 시장
음식	한식, 외국식, 전문음식, 음식점기타, 카페/찻집, 간이음식
숙박	호스텔, 모텔, 펜션/민박, 콘도미니엄, 캠핑, 호텔, 기타숙박
기타관광	교통시설, 기타관광, 데이트코스

콘도미니엄과 캠핑 숙박 카테고리 유지

- 변수(카테고리)

유형	세부유형
자연관광	산, 하천/해양, 공원, 생태
역사관광	종교성지, 역사유적지, 역사유물
체험관광	공예, 농/산/어촌체험, 웰니스관광
문화관광	공연, 테마공원, 전시, 북한관광, 랜드마크, 기타문화, 도시공원, 도시/지역문화
레저스포츠	항공레저, 기타레저, 수상레저, 육상레저
쇼핑	대형마트, 면세점, 쇼핑몰, 백화점, 전문매장/상가, 시장
음식	한식, 외국식, 전문음식, 음식점기타, 카페/찻집, 간식음식
숙박	호스텔, 모텔, 펜션/민박, 콘도미니엄, 캠핑, 호텔, 기타숙박
기타관광	교통시설, 기타관광, 데이트코스

유의미한 데이트코스만 따로 대분류로 만들

교통시설과 기타관광은 여행지 선택의 이유가 될 수 없음



- 변수(카테고리)


카테고리

자연(바다) / 자연(산/공원) / 역사관광 / 체험관광 / 문화관광 /
레저스포츠 / 쇼핑 / 음식 / 숙박 / 데이트코스 / 기타(대형마트)




최종적으로 11개의 카테고리를 생성

기타(대형마트)




1. 경기도 하남시
2. 경기도 고양시
3. 경기도 용인시

데이트코스




1. 제주특별시 제주시
2. 서울특별시 종로구
3. 경상북도 포항시

레저스포츠




1. 강원도 강릉시
2. 강원도 고성군
3. 강원도 동해시

문화관광




1. 경기도 용인시
2. 경기도 고양시
3. 서울특별시 강남구

■ 쇼핑



1. 서울특별시 송파구
2. 서울특별시 중구
3. 강원도 속초시

■ 숙박




1. 강원도 홍천군
2. 강원도 속초시
3. 강원도 강릉시

■ 역사관광




1. 경상북도 경주시
2. 강원도 양양군
3. 서울시 종로구

■ 음식




1. 경기도 용인시
2. 경기도 고양시
3. 경기도 성남시

■ 자연(바다)




1. 강원도 강릉시
2. 강원도 속초시
3. 충청남도 태안군

■ 자연(산, 공원)



1. 제주특별시 서귀포시
2. 강원도 양양군
3. 제주특별시 제주시

■ 체험관광



1. 충청남도 아산시
2. 경기도 화성
3. 경기도 포천



3. 클러스터링

- 클러스터링
- Compositional data

검색 비율이 가장 높은 유형으로 카테고리 부여시
작은 차이로 하나의 카테고리에 분류되는 문제 발생

광역	기초	기타	데이트 코스	레저 스포츠	문화 관광	쇼핑	숙박	음식	역사 관광	자연 (바다)	자연 (산,공원)	체험 관광
강원	양양	0	0	0.077	0.0151	0.0094	0.1224	0.1646	0.0302	0.2362	0.2482	0.0969

→ 강원도 양양의 경우 검색 비율이 가장 높은 유형으로 카테고리 부여시 자연(산,공원)으로 분류됨
하지만 두번째로 검색 비율이 높은 자연(바다)와의 차이는 0.012

검색 비율이 가장 높은 유형으로 카테고리 부여시
작은 차이로 하나의 카테고리에 분류되는 문제 발생

광역	기초	기타	데이트 코스	레저 스포츠	문화 관광	쇼핑	숙박	음식	역사 관광	자연 (바다)	자연 (산,공원)	체험 관광
강원	양양	0	0	0.077	0.0151	0.0094	0.1224	0.1646	0.0302	0.2362	0.2482	0.0969

→ 강원도 양양의 경우 검색 **기존의 방식으로 카테고리 부여시** 자연(산,공원)으로 분류됨

바다와 산, 공원의 비율이 모두 높다는 특징을 반영한 분류 불가능

<유형별 검색 비율>

광역	기초	기타	데이트 코스	레저 스포츠	문화 관광	쇼핑	숙박	음식	역사 관광	자연 (바다)	자연 (산,공원)	체험 관광
강원	강릉	0.0338	0.1735	0.0229	0.0439	0.0525	0.1063	0.0642	0.0668	0.2834	0.0362	0.1165
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
충북	충주	0.0335	5.00E-04	0.3333	0.0366	0.0116	0.0624	0.0235	0.0428	0.016	0.1897	0.2501

각 유형을 토픽으로 보면 각 도시의 토픽 비율로 데이터를 이해할 수 있음




11가지 군집에 속할 확률을 모두 고려해 클러스터링하면

좀 더 정확한 분류를 할 수 있을 것이라는 가정하에 클러스터링 시도

차원이 11개이므로 클러스터링이 잘 되지 않을 수 있음

-> PCA, 요인분석으로 차원을 줄인 후 여러 클러스터링 방법 시도



군집화가 잘 이루어지지 않음

차원이 11개이므로 클러스터링이 잘 되지 않을 수 있음


-> PCA로 차원을 줄인 후 여러 클러스터링 방법 중 k-means 시도(PC5까지 사용)



차원축소를 하지 않고 11개 차원을 모두 사용해 클러스터링 진행


군집화가 잘 이루어지지 않음

K-means




군집의 중심으로 **평균**이용
데이터들을 가장 가까운
중심점을 가진 군집에 할당

K-medoids




중심점으로 **중앙값**이용
데이터들을 가장 가까운
중심점을 가진 군집에 할당

Hierachical clustering



순차적, 계층적 유사한 그룹을
통합하여 군집화

K = 4




Ex) Cluster 3

지역	기타	데이트 코스	...	자연 (바다)
경기도 의정부시	0.4291	0	...	0
경북 포항시	0.0079	0.5616	...	0.1111
부산 사하구	0.2434	0	...	0.5948

비율이 높은 유형이 각기 다른 지역들이 한 클러스터로 군집화됨

K = 8




Ex) Cluster 1


지역	쇼핑	숙박	...	자연 (바다)
부산 수영구	0.0446	0.076	...	0.4612
서울 강남구	0.2276	0.2141	...	0
울산 중구	0.0573	0.0888	...	0.0007

군집화가 잘 되지 않음

K-medoids




계층적 클러스터링




비율이 높은 유형이 각기 다른 지역들이 한 클러스터로 군집화됨
/사실상 군집화가 되지 않음

DBSCAN




밀도기반 클러스터링
클러스터의 수를 정하지 않아도 되며,
기하학적인 모양을 갖는 군집도
잘 찾을 수 있음

GMM




데이터가 여러 다른 형태의
정규분포로 결합돼 있다는 가정 하에
개별 데이터를 동일한 정규분포로
군집화하는 확률적 클러스터링

DBSCAN



GMM



사실상 군집화가 되지 않음

Compositional data

“proportions of some whole”

simplex 공간으로부터 생성된 양수의 요소를 가진 벡터

*simplex: 선형계획법이나 대수위상 등에서 접할 수 있는 개념. 간단함이 특징



simplex 공간 S^D 를 구성하는 D 차원의 벡터 x 는 총합이 k 로 일정할 뿐

각 구성요소 간의 **상대적인 비율**만 알 수 있음

$$S^D = \{X = [x_1, x_2, x_3, \dots, x_D] \in R^D \mid x_i > 0, i = 1, 2, \dots, D ; \sum_{i=1}^D x_i = k\}$$

Compositional data

simplex 공간 S^D 를 구성하는 D 차원의 벡터 x 는 총합이 k 로 일정할 뿐

각 구성요소 간의 상대적인 비율만 알 수 있음

$$S^D = \{X = [x_1, x_2, x_3, \dots, x_D] \in R^D \mid x_i > 0, i = 1, 2, \dots, D ; \sum_{i=1}^D x_i = k\}$$

- $K = 1$ 인 경우 -> standard simplex
 - $K \neq 1$ 인 경우 -> normalization을 통해 1로 만들어 사용
- (S^D 의 특성상 어떤 양수를 곱해서 구성요소간 상대적인 비율이 일정하게 유지됨)

Compositional data의 특징

- ① 데이터의 모든 feature값이 양수
- ② feature의 총합이 모든 데이터에 대해서 상수

광역	기초	기타	데이트 코스	레저 스포츠	문화 관광	쇼핑	숙박	음식	역사 관광	자연 (바다)	자연 (산,공원)	체험 관광
강원	강릉	0.0338	0.1735	0.0229	0.0439	0.0525	0.1063	0.0642	0.0668	0.2834	0.0362	0.1165
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
충북	충주	0.0335	5.00E-04	0.3333	0.0366	0.0116	0.0624	0.0235	0.0428	0.016	0.1897	0.2501

광역	기초	기타	데이트 코스	레저 스포츠	문화 관광	쇼핑	숙박	음식	역사 관광	자연 (바다)	자연 (산,공원)	체험 관광
강원	강릉	0.0338	0.1735	0.0229	0.0439	0.0525	0.1063	0.0642	0.0668	0.2834	0.0362	0.1165
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
충북	충주	0.0335	5.00E-04	0.3333	0.0366	0.0116	0.0624	0.0235	0.0428	0.016	0.1897	0.2501

$$S^D = \{X = [x_1, x_2, x_3, \dots, x_D] \in R^D \mid x_i > 0, i = 1, 2, \dots, D; \sum_{i=1}^D x_i = k\}$$

① 각 요소들은 비율을 의미 -> 모든 feature값이 양수

② 각 행의 총합은 비율의 합이므로 1 -> feature의 총합이 모든 데이터에 대해서 상수

• K ≠ 1인 경우 -> normalization을 통해 1로 만들어 사용

(S^D 의 특성상 어떤 양수를 곱해서 구성요소 간의 상대적인 비율이 일정하게 유지됨)

Compositional data의 특징 만족

■ Aitchison Geometry Vector Space

벡터공간의 정의



일반적인 Euclidian space R^D 에서는 벡터 덧셈, 스칼라 곱셈에 대해 닫혀있고 거리를 구할 수 있음



Compositional data를 구성하는 simplex에 대해서는 이를 그대로 적용할 수 없음

- Compositional data는 덧셈, 스칼라 곱셈에 대해 닫혀있지 않음
- Compositional data의 Euclidian 거리가 비율에 따라 상대적임

Aitchison Geometry Vector Space

Perturbation

$$x \oplus y = \left[\frac{x_1 y_1}{\sum_{i=1}^D x_i y_i}, \frac{x_2 y_2}{\sum_{i=1}^D x_i y_i}, \dots, \frac{x_D y_D}{\sum_{i=1}^D x_i y_i} \right] = C[x_1 y_1, x_2 y_2, \dots, x_D y_D] \quad \forall x, y \in S^D$$

Powering

$$x \odot y = \left[\frac{x_1^\alpha}{\sum_{i=1}^D x_i^\alpha}, \frac{x_2^\alpha}{\sum_{i=1}^D x_i^\alpha}, \dots, \frac{x_D^\alpha}{\sum_{i=1}^D x_i^\alpha} \right] = C[x_1^\alpha, x_2^\alpha, \dots, x_D^\alpha] \quad \forall x \in S^D, \alpha \in R$$

Inner product

$$\langle x, y \rangle = \frac{1}{2D} \sum_{i=1}^D \sum_{j=1}^D \log \frac{x_i}{x_j} \log \frac{y_i}{y_j} \quad \forall x, y \in S^D$$

Norm

$$|X|_a = \sqrt{\frac{1}{2D} \sum_{i=1}^D \sum_{j=1}^D \left(\ln \frac{x_i}{x_j} \right)^2} \quad X \in S^D$$

Distance

$$d_a(X, Y) = \sqrt{\frac{1}{2D} \sum_{i=1}^D \sum_{j=1}^D \left(\ln \frac{x_i}{x_j} - \ln \frac{y_i}{y_j} \right)^2} \quad X, Y \in S^D$$

Aitchison Geometry Vector Space

Perturbation

$$x \oplus y = \left[\frac{x_1 y_1}{\sum_{i=1}^D x_i y_i}, \frac{x_2 y_2}{\sum_{i=1}^D x_i y_i}, \dots, \frac{x_D y_D}{\sum_{i=1}^D x_i y_i} \right] = C[x_1 y_1, x_2 y_2, \dots, x_D y_D] \quad \forall x, y \in S^D$$

Powering

$$x \odot y = \left[\frac{x_1^\alpha}{\sum_{i=1}^D x_i^\alpha}, \frac{x_2^\alpha}{\sum_{i=1}^D x_i^\alpha}, \dots, \frac{x_D^\alpha}{\sum_{i=1}^D x_i^\alpha} \right] = C[x_1^\alpha, x_2^\alpha, \dots, x_D^\alpha] \quad \forall x \in S^D, \alpha \in R$$



Inner product

$$\langle x, y \rangle = \frac{1}{2D} \sum_{i=1}^D \sum_{j=1}^D \log \frac{x_i}{x_j} \log \frac{y_i}{y_j} \quad \forall x, y \in S^D$$

Compositional data의 Aitchison geometry 벡터공간은

유한한 차원을 가진 Hilbert 공간이 되므로

Simplex로 부터 Gram-Schmidt 직교법이나 SVD 등으로 직교좌표계를 구성할 수 있음

Norm

$$\|x\| = \sqrt{\frac{1}{2D} \sum_{i=1}^D \sum_{j=1}^D \left(\ln \frac{x_i}{x_j} \right)^2} \quad x \in S^D$$

Distance

$$d_a(X, Y) = \sqrt{\frac{1}{2D} \sum_{i=1}^D \sum_{j=1}^D \left(\ln \frac{x_i}{x_j} - \ln \frac{y_i}{y_j} \right)^2} \quad X, Y \in S^D$$

Aitchison Geometry Vector Space



Compositional data의 Aitchison geometry 벡터공간은
유한한 차원을 가진 Hilbert 공간이 되므로

Simplex로부터 Gram-Schmidt 직교법이나 SVD 등으로 직교좌표계를 구성할 수 있음

완비 내적 공간으로 유클리드 공간을 일반화한 개념

완비 내적 공간: 다음의 특징을 만족하는 내적이 가능한 벡터 공간

- i) 두 벡터를 이용해 스칼라를 반환하는 함수가 존재
- ii) 공간에 위치한 코시 벡터가 공간 내의 극한값으로 수렴 (= 완비성 complete)

Transformation

1) Isometric log-ratio Transformation (ILR)

Gram-Schmidt 직교법이나 SVD 등의 직교화로 S^D 로 부터 R^{D-1} 의 유클리디안 벡터공간으로 매핑하는 것



Simplex로부터 얻은 직교 좌표 $e_1, \dots, e_{D-1}$ 로부터
 $x \in S^D$ 를 $(\langle x, e_1 \rangle, \dots, \langle x, e_{D-1} \rangle) \in R^{D-1}$ 로 변환 가능



Compositional data는 feature 총합이 모든 데이터에 대해 상수로 일정

직교화를 위해서는 각 기저벡터가 서로 선형독립이어야 하는데

위 simplex의 특징으로 자유도의 개념과 비슷하게 D-1개의 선형 독립인 벡터를 구할 수 있기 때문

■ Transformation

1) Isometric log-ratio Transformation (ILR)

Gram-Schmidt 직교법이나 SVD 등의 직교화로 S^D 로 부터 R^{D-1} 의 **유클리디안 벡터공간으로 매핑**하는 것

ILR변환은 **isometry**를 만족하는 변환

*Isometry : 각 공간에서 정의한 metric 상에서 매핑 전과 후의 데이터의 거리가 일정하게 유지되는 성질





R^{D-1} 의 유클리디안 벡터공간으로 매핑하면
우리가 일반적으로 다루는 operation 적용 가능

Transformation

2) Additive log-ratio Transformation (ALR)

특정 구성 요소로 나눈 각 구성 요소에 자연 로그를 취하는 방법

$$ALR(x) = \left[\log \frac{x_1}{x_D}, \dots, \log \frac{x_{D-1}}{x_D} \right] \in R^{D-1}$$



ALR 변환은 isometry하지 않음




우리는 거리를 기반으로 클러스터링하고자 하므로

ALR 변환은 사용 불가

Transformation

2) Additive log-ratio Transformation (ALR)

특정 구성 요소로 나눈 각 구성 요소에 자연 로그를 취하는 방법



ALR 변환은 isometry하지 않음



우리는 거리를 기반으로 클러스터링하고자 하므로

ALR 변환은 사용 불가

Transformation

3) Center log-ratio Transformation (CLR)

모든 구성 요소의 기하평균으로 나눈 각 구성요소에 자연로그를 취하는 방법

-> 상대적인 비율과 상호의존성을 고려하기 위해 compositional data에 적용됨

$$CLR(x) = v = \left[\log \frac{x_1}{g(x)}, \dots, \log \frac{x_D}{g(x)} \right] \in R^D, \sum_{i=1}^D v_i = \log \frac{x_1 x_2 \dots x_D}{g(x)^D} = \log 1 = 0$$



CLR의 ILR은 위 hyperplane을 spanning할 수 있는 D-1개의 orthonormal basis로 구해짐

이때 ILR은 isometry한 변환이므로 **정확한 거리를 구할 수 있음**

Transformation

3) Center log-ratio Transformation (CLR)

모든 구성 요소의 기하평균으로 나눈 각 구성요소에 자연로그를 취하는 방법

-> 상대적인 비율과 상호의존성을 고려하기 위해 compositional data에 적용됨

비율을 고려한 클러스터링을 하고자 하므로 CLR을 통해 데이터를 변환함

$$CLR(x) = v = \left[\log \frac{x_1}{g(x)}, \dots, \log \frac{x_D}{g(x)} \right] \in R^D, \sum_{i=1}^D v_i = \log \frac{x_1 x_2 \dots x_D}{g(x)^D} = \log 1 = 0$$



CLR의 ILR은 위 hyperplane을 spanning할 수 있는 D-1개의 orthonormal basis로 구해짐

이때 ILR은 isometry한 변환이므로 **정확한 거리를 구할 수 있음**

Aitchison Distance

CLR 변환 요소들 간의 유클리디안 거리


$$d(x_i, x_j) = \sqrt{\sum_{g=1}^D \left[\ln \frac{x_{gi}}{g(x_i)} - \ln \frac{x_{gj}}{g(x_j)} \right]^2}$$

1. Scale Invariance: 두 구성 요소 간의 거리가 스케일에 영향을 받지 않음
2. Perturbation Invariance: 각 구성 요소에 상수를 곱해도 요소 사이의 거리가 변하지 않음
3. Permutation Invariance: 거리 측정이 구성 요소의 재정렬에 불변함
4. Sub-compositional Dominance: 한 구성의 부분 구성이 다른 구성의 해당 부분 구성보다 우위를 가지면 거리를 측정할 때 우위 관계를 반영함(큰 비율을 차지하는 구성의 차이를 더 중요하게 반영)

Aitchison Distance

이러한 특성 때문에 compositional data는
Aitchison 거리를 사용해 분석을 진행

1. Scale Invariance: 두 구성 요소 간의 거리가 스케일에 영향을 받지 않음
2. Perturbation Invariance: 각 구성 요소에 상수를 곱해도 요소 사이의 거리가 변하지 않음
3. Permutation Invariance: 거리 측정이 구성 요소의 재정렬에 불변함
4. Sub-compositional Dominance: 한 구성의 부분 구성이 다른 구성의 해당 부분 구성보다 우위를 가지면 거리를 측정할 때 우위 관계를 반영함(큰 비율을 차지하는 구성의 차이를 더 중요하게 반영)



compositional data의 특징을 고려해 Aitchison 거리를 사용한 최종 군집화 결과

광역시	시군구	거리	가족 동반	...	회사동료 동반	1월 방문자수	...	방문자 증가율	3월 계절 트렌드	언급량 증가율	언급 트렌드	축제	클러스터
강원	강릉	166.7	0.58	...	0.009	2976083	...	1.304	0.5103	0.882	21335	4	3
경기	고양	16.2	0.74	...	0.023	12937504	...	1.143	0.6225	0.827	4515	1	5
부산	해운대	332.2	0.41	...	0.006	5386438	...	1.145	0.3913	0.995	12789	2	3
서울	종로	1.96	0.35	...	0.008	8900897	...	1.328	0.2731	1.031	41479	1	2
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
전북	임실	220.5	0.42	...	0.384	547588	...	1.346	0.8113	1.522	1956	0	1
제주	서귀포	483.4	0.75	...	0.039	4400043	...	1.121	0.6298	1.039	15810	0	1
충남	아산	88.6	0.42	...	0.072	2544841	...	1.132	0.8086	0.819	827	0	8




4. EDA


- 카테고리 별 검색량 수 시각화
- 최종 클러스터링 결과 EDA

Cluster 1


유형별 검색 비율



광역지자체 개수




동반자 유형




Cluster 1은 레저스포츠/자연(산,공원) 검색 비율이 가장 높고, 강원도의 도시들이 가장 많이 속해 있으며, 가족 동반 방문이 가장 많고 혼자서는 방문하지 않는 경향이 상대적으로 두드러짐

Cluster 2


유형별 검색 비율



광역지자체 개수




동반자 유형




Cluster 2는 데이트코스 검색 비율이 가장 높고, 강원/경남/전남의 도시들이 주로 속해 있으며,
가족 동반 방문이 가장 많음

Cluster 3


유형별 검색 비율



광역지자체 개수




동반자 유형




Cluster 3은 자연(바다) 검색 비율이 가장 높고, 전남/부산의 도시들이 주로 속해 있으며,
혼자 방문하는 경향이 강하게 두드러짐

Cluster 4


유형별 검색 비율



광역지자체 개수




동반자 유형




Cluster 4는 역사 관광 검색 비율이 가장 높고, 경남, 전남의 도시들이 주로 속해 있으며, 가족 동반의 방문이 가장 많고, 친구 동반의 방문이 가장 적음

Cluster 5


유형별 검색 비율



광역지자체 개수




동반자 유형




Cluster 5는 쇼핑/문화관광 검색 비율이 가장 높고, 서울, 경기도의 도시들이 주로 속해 있으며,
친구 동반의 방문이 가장 많고, 가족 동반의 방문이 가장 적음

Cluster 6


유형별 검색 비율



광역지자체 개수




동반자 유형




Cluster 6은 자연(산, 공원) 검색 비율이 가장 높고, 충북/경북의 도시들이 주로 속해 있으며, 연인 동반의 방문이 가장 많고, 친구 동반의 방문이 가장 적음

Cluster 7


유형별 검색 비율



광역지자체 개수




동반자 유형




Cluster 7은 기타(대형마트) 검색 비율이 가장 높고, 서울/경기도의 도시들이 주로 속해 있으며, 회사동료 동반의 방문이 가장 많고, 가족 동반의 방문이 가장 적음

Cluster 8


유형별 검색 비율



광역지자체 개수




동반자 유형




Cluster 8은 체험 관광 검색 비율이 가장 높고, 경기도/경북의 도시들이 주로 속해 있으며,
가족 동반의 방문이 가장 많고, 친구 동반의 방문이 가장 적음

클러스터별 방문자 수 월별 추이



Cluster 5는 타 클러스터에 비해 상대적으로 많은 평균 방문자수를 보였으며,
대부분의 클러스터에서 5월에서 8월 사이 방문자 수가 증가함

■ 클러스터별 축제 수 평균



Cluster 3의 도시들에서 가장 많은 대규모 축제가 개최되는 반면,
Cluster 7의 도시들은 대규모 축제의 수가 타 클러스터에 비해 상대적으로 적음

다음 주 예고

AIR TICKET

1. LDA
2. 공간가중행렬
3. 추천 시스템
4. 기대효과

BOARDINGPASS

PASSENGER NAME:

FROM:

TO:

DATE TIME FLIGHT

SEAT GATE

감사합니다

